

平均スナップショット近似に基づく確率的分散削減勾配法

Averaged Snapshot Approximate Incremental SVRG

山富 龍¹
Ryo Yamatomi

浅井 傑²
Suguru Asai

二宮 洋^{1,2}
Hiroshi Ninomiya

湘南工科大学 大学院¹
Graduate University of Shonan Institute of Technology

湘南工科大学²
Shonan Institute of Technology

概要

大規模な機械学習などの有限和最小化問題に対する代表的な最適化手法として確率的勾配降下法 (Stochastic Gradient Descent, SGD) がある。SGD は全データの一部をランダムに抽出し、これを用いてパラメータを更新するため計算効率に優れるが、一部のデータのみを用いて計算された勾配 (確率的勾配) の分散により収束が律速される。この問題を緩和する確率的分散削減勾配法 (Stochastic Variance Reduced Gradient, SVRG) は線形収束を達成しうる。SVRG は一般的な最適化手法でのエポックに相当する外ループと、イテレーションに相当する内ループで構成される最適化手法であり、内ループの開始時点で基準点となるパラメータ (スナップショット) と、そのパラメータにおける全データでの勾配 (フル勾配) の計算を必要とする。フル勾配を確率的勾配の平均で近似する No Full Grad SVRG (NFG SVRG) はフル勾配の計算を回避できる。しかし、フル勾配の近似誤差がノイズとして残り続けるため、反復を重ねても目的関数が真の最適値へ収束せず一定の値で減少が止まってしまう現象 (誤差床) が生じる。本稿では、内ループで得られたパラメータの平均をスナップショットとし、確率的勾配の平均によりフル勾配を近似する Averaged Snapshot Approximate Incremental SVRG (ASAI SVRG) を提案する。提案手法は NFG SVRG と同様にフル勾配の計算を回避しつつ、内ループの全パラメータの平均値 (平均パラメータ) をスナップショットとすることで、NFG SVRG と比べフル勾配の近似誤差の低減を実現している。また、ASAI SVRG は平均パラメータを戻り値とするため、Polyak-Ruppert Averaging と同様のノイズ低減効果が見込める。さらに、外ループごとに平均パラメータをリセットすることで、学習の終盤では最適解の近傍にあるパラメータのみの平均となり、より優れた解へ収束しうる。実験では、Mushroom データセットを用いた二値分類 (平滑かつ強凸な設定) および CIFAR-10 に対する CNN 実験 (非凸な設定) を通じ、提案手法の有効性を検証する。

キーワード 確率的最適化, 分散削減, SVRG, イテレート平均化, 有限和最小化

Abstract

Stochastic Gradient Descent (SGD) is a representative optimizer for large-scale finite-sum minimization. While SGD is computationally efficient, its conver-

gence is limited by the variance of stochastic gradients. Stochastic Variance Reduced Gradient (SVRG) can achieve linear convergence, but it requires a full-gradient computation at a snapshot. No Full Grad SVRG (NFG SVRG) avoids this cost by approximating the full gradient with an average of stochastic gradients, yet an approximation error induces an error floor. We propose Averaged Snapshot Approximate Incremental SVRG (ASAI SVRG), which uses the average of inner-loop parameters as the snapshot and approximates the full gradient by averaged stochastic gradients. The proposed method avoids full-gradient computation while reducing the approximation error via iterate averaging, and theoretically guarantees a lower error floor than NFG SVRG. Experiments on a binary classification task with the Mushroom dataset (smooth strongly convex setting) and a CNN experiment on CIFAR-10 (nonconvex setting) verify the effectiveness of the proposed method.

Key words Stochastic Optimization, Variance Reduction, SVRG, Iterate Averaging, Finite-sum Minimization

1 はじめに

機械学習における多くの学習問題は、大規模な訓練データに対する経験損失の最小化として定式化される [10]。データ数を N 、モデルパラメータを $\mathbf{w} \in \mathbb{R}^d$ とすると、学習の目的は次の有限和最小化問題を解くことである。

$$\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) := \frac{1}{N} \sum_{n=1}^N f_n(\mathbf{w}). \quad (1)$$

ここで $f_n : \mathbb{R}^d \rightarrow \mathbb{R}$ は n 番目の訓練サンプルに対する損失を表し、 $f : \mathbb{R}^d \rightarrow \mathbb{R}$ は経験損失を表す。本稿では最適解を $\mathbf{w}^* = \arg \min_{\mathbf{w}} f(\mathbf{w})$ と記す。

(1) に対する基本的な一次法として勾配降下法 (Gradient Descent, GD) がある [3]。GD は全データを用いて勾配を計算しパラメータを更新するため、目的関数が平滑かつ強凸であれば線形収束するが、勾配の計算コストが全データ数 N に依存するため大規模データに対しては計算負荷が大きい。この計算コストを削減するため、データの一部から計算した勾配を用いる確率的勾配降下

法 (Stochastic Gradient Descent, SGD) [1, 2] が広く用いられる。SGD は一反復あたりの計算が軽量である一方、データの一部のみから計算された勾配には分散が残り、定数の学習率の下では反復を重ねても目的関数が真の最適値まで減少しきらず一定の値で減少が止まる現象が生じる。この現象は誤差床と呼ばれ、高精度な解を得るには学習率の減衰が必要となるため、平滑かつ強凸な設定でも収束レートは一般に劣線形となる。

この分散を明示的に削減する手法として、確率的分散削減勾配法 (Stochastic Variance Reduced Gradient, SVRG) [4] がある。SVRG は外ループと内ループで構成される最適化手法であり、内ループの開始時点で基準点となるパラメータを固定し、そのパラメータにおいて全データを用いて計算された勾配を求める。この基準点はスナップショットと呼ばれ、分散削減の参照として用いられる。SVRG はこの勾配を用いて確率的勾配を補正することで分散を削減し、平滑かつ強凸な設定では定数の学習率の下で線形収束が得られる。一方で、SVRG は外ループごとに全データに対する勾配を計算する必要があり、大規模問題ではその計算コストがボトルネックとなりうる。

この問題を緩和する手法として、No Full Grad SVRG (NFG SVRG) [5] が提案されている。NFG SVRG は、全データから計算された勾配の代わりに直前の内ループで得た確率的勾配の平均を用いることで、外ループごとにデータ数に依存する計算を回避する。ただし、平均勾配と真の全データ勾配との間には近似誤差が残るため、目的関数は一般にその誤差で決まる誤差床へ収束する。したがって、全データの勾配を近似する枠組みでは、スナップショットの選び方が近似誤差の大きさ、ひいては収束先の上界に影響する。

本稿では、全データの勾配計算を回避しつつ分散を削減する手法において、スナップショットの選び方が近似誤差へ与える影響を明らかにする。さらに、内ループで得たパラメータの平均をスナップショットとする Averaged Snapshot Approximate Incremental SVRG (ASAI SVRG) を提案し、その収束性を議論する。提案手法は、NFG SVRG と同様に全データの勾配計算を避けつつ、パラメータの平均化により参照点を安定化する。ASAI SVRG は平均パラメータを戻り値とするため、Polyak–Ruppert Averaging と同様のノイズ低減効果が見込める。加えて、外ループごとに平均パラメータをリセットするため、学習の終盤においては最適解の近傍にあるパラメータのみの平均値となり、より優れた解へ収束しうる。平均パラメータは内ループの軌跡に最も近いスナップショットとなり、近似誤差を理論的に小さく抑えられる。提案手法の有効性は、Mushroom データセットを用いた二値分類 (平滑かつ強凸な設定) [11] および CIFAR-10 データセットを用いた CNN 実験 (非凸な設定) [12] により検証する。本研究の貢献は次の 3 点である。

- 平均パラメータをスナップショットとした ASAI SVRG の提案

- 提案手法と関連手法を統一的なワークフローの下での収束の評価
- フル勾配を平均勾配で近似する際に、最良のスナップショットが平均パラメータであることの論理的な証明

2 準備と関連研究

本章では、提案手法の基礎となる最適化手法を整理する。まず勾配降下法と確率的勾配降下法を概観し、次に確率的勾配の分散を削減する手法を述べ、最後にイテレート平均化手法を紹介する。

2.1 勾配降下法と確率的勾配降下法

(1) に対する最も基本的な一次法が勾配降下法 (Gradient Descent, GD) である [3]。GD は各反復において全 N 個のデータを用いて勾配を計算し、次式でパラメータを更新する。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla f(\mathbf{w}_k). \quad (2)$$

ここで $\nabla f(\mathbf{w}_k) = \frac{1}{N} \sum_{n=1}^N \nabla f_n(\mathbf{w}_k)$ は全データから計算された勾配であり、フル勾配と呼ぶ。フル勾配はデータ全体の情報を反映するため分散をもたないが、その計算コストは全データ数 N に依存する。目的関数が平滑かつ強凸である場合、適切な定数の学習率の下で GD は線形収束する [3]。一方で、大規模データに対してはフル勾配の計算が高コストとなるため、実用上のスケラビリティに課題がある。

GD の計算コストを削減するため、確率的勾配降下法 (Stochastic Gradient Descent, SGD) [1, 2] が広く用いられる。SGD では、データのインデックスの部分集合であるミニバッチ $\mathcal{B}_k \subset \{1, \dots, N\}$ をランダムに抽出し、次式でパラメータを更新する。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{1}{|\mathcal{B}_k|} \sum_{n \in \mathcal{B}_k} \nabla f_n(\mathbf{w}_k). \quad (3)$$

本稿の理論解析では、解析の簡便化のためミニバッチサイズ 1 (オンライン学習の設定) に限定して議論する。先行研究 [4, 5] もオンライン学習で理論を展開している。オンライン学習における SGD は、単一のインデックス $n_k \in \{1, \dots, N\}$ を抽出し、次式でパラメータを更新する。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla f_{n_k}(\mathbf{w}_k). \quad (4)$$

SGD で用いる勾配はデータの一部から計算された近似勾配であり、確率的勾配と呼ぶ。確率的勾配はフル勾配の不偏推定であるが、データの抽出に伴うランダム性から分散が生じる。この分散のため、定数の学習率の下では反復を重ねても目的関数が真の最適値まで減少しきらず、ある値で減少が止まる現象が生じる。この現象は誤差床と呼ばれ、高精度な解を得るには学習率の減衰が必要となる。その結果、平滑かつ強凸な設定でも収束レートは一般に劣線形となる。

Algorithm 1 SVRG

Require: 初期値 $\mathbf{w}_0^0$, 学習率 η , 外ループ数 S , 内ループ長 K

```
1:  $\mathbf{z}_0 \leftarrow \mathbf{w}_0^0$ 
2: for  $s = 0, 1, \dots, S-1$  do
3:    $\mathbf{w}_s^0 \leftarrow \mathbf{z}_s$ 
4:    $\mathbf{g}_s \leftarrow \nabla f(\mathbf{z}_s)$ 
5:   for  $k = 0, 1, \dots, K-1$  do
6:     インデックス  $n_s^k$  を抽出
7:      $\mathbf{v}_s^k \leftarrow \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s$ 
8:      $\mathbf{w}_s^{k+1} \leftarrow \mathbf{w}_s^k - \eta \mathbf{v}_s^k$ 
9:   end for
10:   $\mathbf{z}_{s+1}$  を  $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$  からランダム選択
11: end for
```

Ensure: $\mathbf{z}_S$

2.2 確率的勾配分散削減手法

2.2.1 SVRG

確率的分散削減勾配法 (Stochastic Variance Reduced Gradient, SVRG) [4] は、確率的勾配の分散を明示的に削減する手法である。SVRG は外ループと内ループで構成され、外ループの開始時に基準点となるパラメータを固定する。この基準点はスナップショットと呼ばれ、分散削減の参照として用いられる。SVRG のアルゴリズムを Algorithm 1 に示す。外ループの番号を s 、内ループの番号を k 、内ループ長を K 、スナップショットを $\mathbf{z}_s$ とすると、補正勾配は次式で定義される。

$$\mathbf{v}_s^k = \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s. \quad (5)$$

ここで n_s^k は、外ループ s 、内ループ k で抽出したデータのインデックスを表す。補正勾配とは、確率的勾配からスナップショット上の勾配を差し引き、フル勾配を加えることで分散を低減した勾配推定量である。SVRG では $\mathbf{g}_s$ をスナップショット $\mathbf{z}_s$ におけるフル勾配として

$$\mathbf{g}_s = \nabla f(\mathbf{z}_s) = \frac{1}{N} \sum_{n=1}^N \nabla f_n(\mathbf{z}_s) \quad (6)$$

とし、パラメータを次式で更新する。

$$\mathbf{w}_s^{k+1} = \mathbf{w}_s^k - \eta \mathbf{v}_s^k. \quad (7)$$

パラメータ $\mathbf{w}$ がスナップショット $\mathbf{z}_s$ の近傍にあるとき、 $\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{z}_s)$ は小さくなる。さらに $\mathbf{w}$ が最適解 $\mathbf{w}^*$ へ近づくにつれ、補正勾配の分散は減少する。平滑かつ強凸な設定では、適切な定数の学習率の下で線形収束が示される [4]。

一方で、SVRG は外ループごとに (6) のフル勾配を必要とし、その計算コストが全データ数 N に依存する。大規模問題では、このコストがボトルネックとなりうる。

2.2.2 No Full Grad SVRG

フル勾配の計算を回避する分散削減手法として、No Full Grad SVRG (NFG SVRG) が提案されている [5]。NFG SVRG のアルゴリズムを Algorithm 2 に示す。NFG SVRG は、(5) の $\mathbf{g}_s$ をフル勾配の代わりに、直前の内ループで得た確率的勾配の平均

$$\mathbf{g}_s = \frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) \quad (8)$$

で近似する。この平均勾配は、フル勾配の代替として外ループごとの全データ計算を不要にする。

SVRG 系の手法では、次の外ループのスナップショット $\mathbf{z}_{s+1}$ の選び方として、内ループのパラメータ列 $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ から一様にランダム選択する方法と、内ループの最終パラメータ $\mathbf{w}_s^K$ を採用する方法とが知られている。実装では後者（最終パラメータの採用）が用いられることが多い。一方、本稿の理論解析では前者、すなわち $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ からランダム選択する場合に限定して議論する。この扱いの妥当性は、次の三点から説明できる。

第一に、証明上の技術的制約がある。内ループの不等式を足し合わせる望遠和 (telescoping sum) に基づく解析では、自然に導出されるのは全ステップの平均誤差 $\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)]$ である。最終点 $\mathbf{w}_s^K$ 単体の誤差のみを分離して評価することは、数学的に極めて難しい。

第二に、この評価は安全側の上限保証として機能し、先行研究でも標準的である。ランダム選択は内ループ内の平均的な挙動を評価しており、実用上の最終パラメータに対する最悪ケースの上界を与える。SVRG の原論文 [4] をはじめとする先行研究でも、解析ではランダム選択を仮定し、実装では最終パラメータを用いる、という分担が採用されている。

第三に、提案手法である ASAI SVRG はこのギャップを直接解消する。ASAI SVRG は内ループの平均パラメータをスナップショットおよび戻り値とするため、凸関数に対する Jensen の不等式により $f(\mathbf{z}_{s+1}) = f(\frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k) \leq \frac{1}{K} \sum_{k=0}^{K-1} f(\mathbf{w}_s^k)$ が成り立つ。したがって、平均パラメータを用いる実装と、平均誤差を評価する理論解析とが整合する。本稿では NFG SVRG についても、理論解析の文脈では $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ からランダム選択する場合に限定して議論を進める。

フル勾配と平均勾配の差を近似誤差と定義する。近似誤差とは、平均勾配 $\mathbf{g}_s$ が真のフル勾配 $\nabla f(\mathbf{z}_s)$ からどれだけずれるかを定量化する量であり、次式で表される。

$$\mathbf{e}_s := \mathbf{g}_s - \nabla f(\mathbf{z}_s). \quad (9)$$

この近似誤差を用いると、補正勾配は期待値の意味で

$$\mathbf{v}_s^k = \nabla f(\mathbf{w}_s^k) + \mathbf{e}_s \quad (10)$$

と書け、バイアス $\mathbf{e}_s$ を含む。SVRG ではフル勾配を用いるため $\mathbf{e}_s = \mathbf{0}$ であり、バイアスは生じない。一方、

Algorithm 2 No Full Grad SVRG

Require: 初期値 $\mathbf{w}_0^0$, 学習率 η , 外ループ数 S , 内ループ長 K

```
1:  $\mathbf{z}_0 \leftarrow \mathbf{w}_0^0$ 
2: for  $s = 0, 1, \dots, S - 1$  do
3:    $\mathbf{w}_s^0 \leftarrow \mathbf{z}_s$ 
4:    $\bar{\mathbf{g}}^0 = \mathbf{0}$ 
5:   for  $k = 0, 1, \dots, K - 1$  do
6:     インデックス  $n_s^k$  を抽出
7:      $\bar{\mathbf{g}}^{k+1} \leftarrow \frac{k}{k+1} \bar{\mathbf{g}}^k + \frac{1}{k+1} \nabla f_{n_s^k}(\mathbf{w}_s^k)$ 
8:      $\mathbf{v}_s^k \leftarrow \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s$ 
9:      $\mathbf{w}_s^{k+1} \leftarrow \mathbf{w}_s^k - \eta \mathbf{v}_s^k$ 
10:  end for
11:   $\mathbf{z}_{s+1}$  を  $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$  からランダム選択
12:   $\mathbf{g}_{s+1} = \bar{\mathbf{g}}^K$ 
13: end for
Ensure:  $\mathbf{z}_S$ 
```

NFG SVRG では一般に $\mathbf{e}_s \neq \mathbf{0}$ であり, この近似誤差が残存する. その結果, NFG SVRG の目的関数の値は近似誤差の大きさで決まる誤差床に収束する. 誤差床とは, 近似誤差に起因して目的関数がある値より下に減少できなくなる現象であり, 近似誤差が小さいほど誤差床も低くなる.

2.3 イテレート平均化手法

確率的勾配に伴うノイズを抑える別系統の手法として, イテレート平均化がある. 学習率スケジューリングを不要にする Schedule-Free 最適化 [9] でも, 平均化が安定化の中核として用いられている.

2.3.1 Polyak–Ruppert Averaging

Polyak–Ruppert Averaging [6, 7] は, パラメータの更新とは独立にパラメータ列の平均を保持し, その平均パラメータを戻り値とする最適化手法である. 平均パラメータとは, 過去のパラメータの算術平均であり, 確率的ノイズの影響を平滑化した安定なパラメータ推定を与える. 一般のミニバッチ設定では, 更新は次式で与えられる.

$$\begin{cases} \mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{1}{|\mathcal{B}_k|} \sum_{n \in \mathcal{B}_k} \nabla f_n(\mathbf{w}_k), \\ \mathbf{x}_{k+1} = \frac{k}{k+1} \mathbf{x}_k + \frac{1}{k+1} \mathbf{w}_{k+1}. \end{cases} \quad (11)$$

ここで $\mathbf{x}_k$ はステップ k までの平均パラメータを表し, $\mathbf{x}_0 = \mathbf{0}$ とする. (11) の第 2 式は平均パラメータの逐次更新であり, 過去のパラメータを保存せずに平均を維持できる. Polyak–Ruppert Averaging はパラメータの平均化により確率的ノイズが平滑化され, 推論に用いる $\mathbf{x}_k$ が安定する. ただし最適化の軌跡そのものは $\mathbf{w}_k$ 上で進

むため, 学習過程は依然として確率的勾配の分散の影響を受けうる.

2.3.2 Primal Averaging

Primal averaging [8] は, 勾配を計算する点にも平均パラメータを用いる手法である. 一般のミニバッチ設定では, 更新は次式で与えられる.

$$\begin{cases} \mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{1}{|\mathcal{B}_k|} \sum_{n \in \mathcal{B}_k} \nabla f_n(\mathbf{x}_k), \\ \mathbf{x}_{k+1} = \frac{k}{k+1} \mathbf{x}_k + \frac{1}{k+1} \mathbf{w}_{k+1}. \end{cases} \quad (12)$$

この手法は, 平均パラメータ $\mathbf{x}_k$ で勾配を計算することで学習軌跡自体の安定化を図る. 一方で, 収束が遅くなる場合があることが指摘されている [9].

すなわち, SVRG は毎回の勾配更新における推定量の精度 (分散の小ささ) を高める手法であるのに対し, Polyak–Ruppert Averaging は最終的に得られる解の精度 (確率的ノイズの打ち消しによる安定性) を高める手法である.

以上より, 分散削減は確率的勾配の推定品質を改善し, イテレート平均化はパラメータ列の平滑化により安定性を高める. 本稿の提案手法は, NFG SVRG におけるスナップショットの選択にイテレート平均化の知見を取り入れ, $\mathbf{e}_s$ の低減を図るものである.

3 提案手法

本章では Averaged Snapshot Approximate Incremental SVRG (ASAI SVRG) を述べる. つづいて, 従来手法との収束を比較する.

3.1 ASAI SVRG

SVRG はフル勾配により分散を削減できる一方で, 大規模データではその計算が律速となる. NFG SVRG はこの計算を確率的勾配の平均で代替するが, スナップショットの選び方によっては近似誤差が大きく残り, 収束先の誤差床が悪化する. ASAI SVRG は, 分散削減の参照点を内ループで得たパラメータの平均として構成する. 平均化はミニバッチ学習に伴う揺らぎを平滑化し, フル勾配を近似する際の決定論的なずれを小さく抑える. 平均パラメータは内ループの軌跡に対して最も近い参照点となり, 近似誤差のうちスナップショット位置に依存する項を最小化できる. したがって, 提案手法はフル勾配の計算を回避しつつ, NFG SVRG よりも小さい近似誤差, すなわちより低い誤差床を理論的に保証できる.

ASAI SVRG は (5) の分散削減更新を用い, $\mathbf{g}_s$ は NFG SVRG と同様に確率的勾配の平均で近似する. 相違点はスナップショットの構成であり, 内ループで得られたパラメータ $\mathbf{w}_s^0, \dots, \mathbf{w}_s^{K-1}$ の平均を次の外ループのスナップショットとする. 実装上は, 平均パラメータおよび平均勾配を逐次更新により維持するため, 内ループの全パ

ラメータを保存する必要はない．内ループのステップ k において、まず

$$\bar{\mathbf{z}}_s^{k+1} = \frac{k}{k+1} \bar{\mathbf{z}}_s^k + \frac{1}{k+1} \mathbf{w}_s^k, \quad (13)$$

$$\bar{\mathbf{g}}_s^{k+1} = \frac{k}{k+1} \bar{\mathbf{g}}_s^k + \frac{1}{k+1} \nabla f_{n_s^k}(\mathbf{w}_s^k) \quad (14)$$

により平均を更新し、その後に補正勾配の計算とパラメータ更新を行う．各エポック終了時に $\mathbf{z}_{s+1} = \bar{\mathbf{z}}_s^K$, $\mathbf{g}_{s+1} = \bar{\mathbf{g}}_s^K$ と置く．(13) は $\mathbf{w}_s^0, \dots, \mathbf{w}_s^{K-1}$ の平均と一致し、(14) は確率的勾配 K 個の平均と一致する．

ASAI SVRG のアルゴリズムを Algorithm 3 に示す．初期の平均勾配を $\mathbf{g}_0 = \mathbf{0}$ とおく．第 1 エポックでは $\mathbf{w}_0^0 = \mathbf{z}_0$ かつ $\mathbf{g}_0 = \mathbf{0}$ であるため、補正勾配は

$$\mathbf{v}_0^k = \nabla f_{n_0^k}(\mathbf{w}_0^k) - \nabla f_{n_0^k}(\mathbf{z}_0) + \mathbf{g}_0 = \mathbf{0} \quad (15)$$

となり、パラメータは更新されない．その結果、第 1 エポックでは平均勾配の蓄積のみが行われる．第 2 エポック以降では、蓄積した平均勾配を用いて分散削減更新を行い、同時に平均パラメータと平均勾配を逐次更新する．

ASAI SVRG におけるパラメータ平均化の役割は、二つの古典的な平均化手法との対比により明確になる．Polyak–Ruppert Averaging[6, 7] は、更新則には介入せず、パラメータ列の平均を推論に用いることで確率的ノイズを低減する．ASAI SVRG も平均パラメータを戻り値とするため同様のノイズ低減が見込める一方、その平均を次エポックのスナップショットとしても用いる．外ループごとに平均をリセットするため、学習の終盤では最適解の近傍にあるパラメータのみが平均され、より優れた解へ収束しうる．Primal Averaging[8] は平均パラメータにおいて勾配を計算し、最適化の軌跡そのものを安定化する．ASAI SVRG の平均確率的勾配 $\mathbf{g}_s$ はこれに近く、フル勾配の近似が平均化された軌跡に沿って評価される．以上より、ASAI SVRG はパラメータ平均化を SVRG の枠組みに組み込んだ手法であり、平均パラメータは平均勾配に対して自然な参照点となる．3.2 節で述べるように、これによりフル勾配の近似誤差を NFG SVRG と比べ抑えられる．

3.2 提案手法と従来手法の収束比較

本節では、補正勾配の性質と目的関数の値の収束上界を与え、SVRG, NFG SVRG, ASAI SVRG を比較する．比較のため、まず SVRG 系手法の統一ワークフローを Algorithm 4 に示す．各手法は、外ループの開始時に $\mathbf{w}_s^0 = \mathbf{z}_s$ と置き、内ループで補正勾配による更新を行う．手法ごとの相違は、 $\mathbf{g}_s$ の計算方法およびスナップショットの更新規則のみである．なお、NFG SVRG の論文 [5] は内ループの最終パラメータをスナップショットとするが、本稿の収束議論では $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ からランダム選択する場合に限定する．この扱いは、2.2 節で述べた望遠和に基づく解析上の制約、および最終パラメータに対する安全側の上界保証として妥当である．

Algorithm 3 ASAI SVRG

Require: 初期値 $\mathbf{w}_0$, 学習率 η , 外ループ数 S , 内ループ長 K

```

1:  $\mathbf{z}_0 \leftarrow \mathbf{w}_0$ ,  $\mathbf{g}_0 \leftarrow \mathbf{0}$ 
2: for  $s = 0, 1, \dots, S-1$  do
3:    $\mathbf{w}_s^0 \leftarrow \mathbf{z}_s$ 
4:    $\bar{\mathbf{z}}^0 \leftarrow \mathbf{0}$ ,  $\bar{\mathbf{g}}^0 \leftarrow \mathbf{0}$ 
5:   for  $k = 0, 1, \dots, K-1$  do
6:     インデックス  $n_s^k$  を一様に抽出
7:      $\bar{\mathbf{z}}^{k+1} \leftarrow \frac{k}{k+1} \bar{\mathbf{z}}^k + \frac{1}{k+1} \mathbf{w}_s^k$ 
8:      $\bar{\mathbf{g}}^{k+1} \leftarrow \frac{k}{k+1} \bar{\mathbf{g}}^k + \frac{1}{k+1} \nabla f_{n_s^k}(\mathbf{w}_s^k)$ 
9:      $\mathbf{v}_s^k \leftarrow \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s$ 
10:     $\mathbf{w}_s^{k+1} \leftarrow \mathbf{w}_s^k - \eta \mathbf{v}_s^k$ 
11:   end for
12:    $\mathbf{z}_{s+1} \leftarrow \bar{\mathbf{z}}^K$ ,  $\mathbf{g}_{s+1} \leftarrow \bar{\mathbf{g}}^K$ 
13: end for
Ensure:  $\mathbf{z}_S$ 

```

表 1: 各手法のスナップショットとフル勾配推定

手法	$\mathbf{z}_s$	$\mathbf{g}_s$
SVRG	$\{\mathbf{w}_{s-1}^k\}_{k=0}^{K-1}$ からランダム選択	$\nabla f(\mathbf{z}_s)$
NFG SVRG	$\{\mathbf{w}_{s-1}^k\}_{k=0}^{K-1}$ からランダム選択	$\frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k)$
ASAI SVRG	$\frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_{s-1}^k$	$\frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k)$

表 1 に、SVRG, NFG SVRG, ASAI SVRG のスナップショットとフル勾配推定の対応を示す．

仮定 本稿の収束解析では、次の仮定を置く．

- Assumption 1 (L -平滑性) : 各 f_n は L -平滑である．すなわち、任意の $\mathbf{w}, \mathbf{w}'$ に対して

$$\|\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}')\| \leq L \|\mathbf{w} - \mathbf{w}'\| \quad (16)$$

が成り立つ．(16) は、パラメータの変化に対する勾配の変化率が L で抑えられることを表す．これより

$$f_n(\mathbf{w}) - f_n(\mathbf{w}') - \langle \nabla f_n(\mathbf{w}'), \mathbf{w} - \mathbf{w}' \rangle \leq \frac{L}{2} \|\mathbf{w} - \mathbf{w}'\|^2 \quad (17)$$

が従う．(17) は、後続の補題 1 および補題 2 で勾配差分を目的関数の値へ結びつける際に用いる．

- Assumption 2 (凸性) : 各 f_n は凸である．すなわち、任意の $\mathbf{w}, \mathbf{w}'$ および任意の $\lambda \in [0, 1]$ に対して、 $f_n(\lambda \mathbf{w} + (1-\lambda)\mathbf{w}') \leq \lambda f_n(\mathbf{w}) + (1-\lambda)f_n(\mathbf{w}')$ が成り立つ．これより、任意の $\mathbf{w}, \mathbf{w}'$ に対して

$$f_n(\mathbf{w}) \geq f_n(\mathbf{w}') + \langle \nabla f_n(\mathbf{w}'), \mathbf{w} - \mathbf{w}' \rangle \quad (18)$$

が従う．各 f_n が凸であれば経験損失 f も凸であり、ASAI における平均スナップショットに対する Jensen

Algorithm 4 SVRG 系手法の統一ワークフロー

Require: 初期値 $\mathbf{w}_0^0$, 学習率 η , 外ループ数 S , 内ループ長 K

```

1:  $\mathbf{z}_0 \leftarrow \mathbf{w}_0^0$ 
2: for  $s = 0, 1, \dots, S-1$  do
3:    $\mathbf{w}_s^0 \leftarrow \mathbf{z}_s$ 
4:   SVRG:  $\mathbf{g}_s \leftarrow \nabla f(\mathbf{z}_s)$ 
5:   NFG / ASAI:  $\mathbf{g}_s \leftarrow \frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_s^k}(\mathbf{w}_{s-1}^k)$ 
6:   for  $k = 0, 1, \dots, K-1$  do
7:     インデックス  $n_s^k$  を抽出
8:      $\mathbf{v}_s^k \leftarrow \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s$ 
9:      $\mathbf{w}_s^{k+1} \leftarrow \mathbf{w}_s^k - \eta \mathbf{v}_s^k$ 
10:  end for
11:  SVRG / NFG:  $\mathbf{z}_{s+1}$  を  $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$  からランダム選択
12:  ASAI:  $\mathbf{z}_{s+1} \leftarrow \frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k$ 
13: end for
Ensure:  $\mathbf{z}_S$ 
  
```

の不等式や、補題 1 における補助関数の非負性の議論に用いる。

- Assumption 3 (μ -強凸性) : f は μ -強凸である。すなわち、任意の $\mathbf{w}, \mathbf{w}'$ に対して

$$f(\mathbf{w}) - f(\mathbf{w}') - \langle \nabla f(\mathbf{w}'), \mathbf{w} - \mathbf{w}' \rangle \geq \frac{\mu}{2} \|\mathbf{w} - \mathbf{w}'\|^2 \quad (19)$$

が成り立つ。(19) は、目的関数が最適解に向かって十分に曲がっていることを表す。特に、 $\mathbf{w}' = \mathbf{w}^*$ とおくと

$$f(\mathbf{w}) - f(\mathbf{w}^*) \geq \frac{\mu}{2} \|\mathbf{w} - \mathbf{w}^*\|^2, \quad (20)$$

$$f(\mathbf{w}) - f(\mathbf{w}^*) \geq \frac{1}{2\mu} \|\nabla f(\mathbf{w})\|^2 \quad (21)$$

が得られる。(20) はパラメータ距離を目的関数ギャップへ変換するために用い、(21) は勾配ノルムを目的関数ギャップへ変換するために用いる。

- Assumption 4 (分散の一樣有界性) : 確率的勾配の分散は一樣に有界である。すなわち、ある $\sigma^2 \geq 0$ が存在し、任意の $\mathbf{w}$ に対して

$$\mathbb{E}_n[\|\nabla f_n(\mathbf{w}) - \nabla f(\mathbf{w})\|^2] \leq \sigma^2 \quad (22)$$

が成り立つ。(22) は、ミニバッチ学習に伴う勾配ノイズがパラメータ位置によらず有界であることを表す。この式は、定理 2 における近似誤差のノイズ項を抑えるために用いる。

フル勾配の近似誤差 $\mathbf{e}_s$ は (9) で定義される。この量は、平均勾配がスナップショットにおける真のフル勾配からどれだけずれるかを表し、NFG SVRG および ASAI SVRG の誤差床を支配する。このとき補正勾配は

$$\begin{aligned} \mathbf{v}_s^k &= \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \mathbf{g}_s \\ &= \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{z}_s) + \nabla f(\mathbf{z}_s) + \mathbf{e}_s \end{aligned} \quad (23)$$

と書ける。さらに n_s^k に関する条件付き期待値をとると

$$\mathbb{E}_{n_s^k}[\mathbf{v}_s^k] = \mathbb{E}[\mathbf{v}_s^k \mid \mathbf{w}_s^k, \mathbf{z}_s, \mathbf{e}_s] = \nabla f(\mathbf{w}_s^k) + \mathbf{e}_s \quad (24)$$

となる。本稿では、添字付きの期待値 $\mathbb{E}_{n_s^k}[\cdot]$ により、データのインデックス n_s^k 以外を固定した条件付き期待値を表す。すなわち、(24) および以降の議論における

$$\mathbb{E}_n[\cdot] = \mathbb{E}[\cdot \mid \text{固定された条件}] \quad (25)$$

である。特に (24) は、補正勾配がフル勾配に近似誤差を加えた量として振る舞うことを示し、補題 3 の展開で用いる。なお、(10) は (24) の右辺と同一の関係を表す。

補題

補題 1 (勾配差分の平均の期待値の上界). Assumption 1 および Assumption 2 の下で、任意の $\mathbf{w}$ に対して

$$\mathbb{E}_n[\|\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}^*)\|^2] \leq 2L(f(\mathbf{w}) - f(\mathbf{w}^*)) \quad (26)$$

が成り立つ。

(26) は、各サンプル勾配と最適解における勾配との差の二乗平均が、目的関数ギャップで上から抑えられることを表す。本補題は、補題 2 で補正勾配の二次モーメントを評価する際の基本不等式として用いる。証明は付録 A に示す。

補題 2 (補正勾配の分散). Assumption 1 の下で

$$\begin{aligned} \mathbb{E}_{n_s^k}[\|\mathbf{v}_s^k\|^2] &\leq 6L(f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + 18L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) + 6\|\mathbf{e}_s\|^2 \end{aligned} \quad (27)$$

が成り立つ。

(27) は、補正勾配の大きさの二乗期待値が、現在点の目的関数ギャップ、スナップショットの目的関数ギャップ、および近似誤差の三項で抑えられることを表す。本補題は、補題 3 でパラメータ更新後の距離を評価する際に用いる。証明は付録 A に示す。

定数

$$c_1 = 2\eta(1 - 3\eta L), \quad c_2 = 18\eta^2 L, \quad c_3 = 6\eta^2 + \frac{\eta}{\mu} \quad (28)$$

を導入する。ここで c_1 は目的関数ギャップの減少に寄与する係数、 c_2 はスナップショットのギャップが残差として残る係数、 c_3 は近似誤差が残差として残る係数を表す。

補題 3 (最適解と現在のパラメータの距離の期待値の上界). $0 < \eta < 1/(3L)$ の下で

$$\begin{aligned} c_1 \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \\ \leq \left(Kc_2 + \frac{2}{\mu} \right) \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] \\ + Kc_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (29)$$

が成り立つ.

(29) は, 内ループにおける目的関数ギャップの総和が, スナップショットのギャップと近似誤差で上から抑えられることを表す. 本補題は, スナップショット更新後の収束再帰式を導く中核として用いる. 証明は付録 A に示す.

定理

定理 1 (各手法の収束特性). Assumption 1–4 の下で $0 < \eta < 1/(3L)$ とし, 定数 c_1, c_2, c_3 を (28) で, 収縮係数 ρ を

$$\rho = \frac{Kc_2 + 2/\mu}{Kc_1} \quad (30)$$

で定める. このとき

$$\mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \leq \rho \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] + \frac{c_3}{c_1} \mathbb{E}[\|\mathbf{e}_s\|^2] \quad (31)$$

が成り立つ.

(31) は, 次エポックの目的関数ギャップが, 現エポックのギャップの収縮項と近似誤差項の和で抑えられることを表す.

以下に導出の概略を示す. $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ から一様ランダムに選ぶ場合,

$$\mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (32)$$

である. したがって

$$K \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] = \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (33)$$

となる. 一方, $\mathbf{z}_{s+1} = \frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k$ とする ASAI の場合は, Assumption 2 より f は凸であるから Jensen の不等式が使える,

$$f(\mathbf{z}_{s+1}) = f\left(\frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k\right) \leq \frac{1}{K} \sum_{k=0}^{K-1} f(\mathbf{w}_s^k) \quad (34)$$

となる. よって同様に

$$K \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \leq \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (35)$$

が成り立つ. いずれの場合も (29) より

$$\begin{aligned} Kc_1 \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \\ \leq \left(Kc_2 + \frac{2}{\mu} \right) \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] \\ + Kc_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (36)$$

となり, 整理すると (31) を得る.

SVRG は $\mathbf{e}_s = \mathbf{0}$ であるため, $\rho < 1$ となるよう η を選べば線形収束する. NFG SVRG および ASAI SVRG では右辺第二項が残り, 目的関数は近似誤差で決まる誤差床へ収束する. 証明は付録 B に示す.

定理 2 (誤差床の上界比較). Assumption 1–4 の下で, 同一の内ループ軌跡に対して

$$\mathbb{E}[\|\mathbf{e}_s^{\text{ASAI}}\|^2] \leq \mathbb{E}[\|\mathbf{e}_s^{\text{NFG}}\|^2] \quad (37)$$

が成り立つ. すなわち, 平均パラメータはスナップショットとして最良の選択である.

(37) は, ASAI SVRG の近似誤差が NFG SVRG の近似誤差を超えないことを表す. 平均パラメータは $\omega(\mathbf{z}_s) = \sum_{k=0}^{K-1} \|\mathbf{w}_{s-1}^k - \mathbf{z}_s\|^2$ を最小化する. この量は内ループの各パラメータからスナップショットまでの二乗距離の和であり, 近似誤差の決定論的な成分を支配する. 一方, 確率的な成分はスナップショットの選択に依存しない. したがって, ASAI SVRG は NFG SVRG と比べ近似誤差が小さく, (31) における誤差床をより低く抑えられる. 証明は付録 B に示す.

以上をまとめると, 次が言える.

- SVRG は $\mathbf{e}_s = \mathbf{0}$ であるため, 適切な η の下で $\rho < 1$ となり線形収束する.
- NFG SVRG および ASAI SVRG は近似誤差の影響により, 目的関数は誤差床へ収束する.
- ASAI SVRG は NFG SVRG より $\mathbb{E}[\|\mathbf{e}_s\|^2]$ が小さいため, (31) 右辺の誤差項が小さく, 目的関数の値の上界をより小さく抑えられる.

すなわち ASAI SVRG は, フル勾配の計算を避ける NFG 型の枠組みを保ちつつ, イテレート平均化に基づくスナップショット選択により近似誤差を低減する手法である.

4 実験

理論解析の妥当性を検証するため, 異なる問題の設定に基づく 2 つの実験を行う. 第一の実験では, 理論の仮定を満たす平滑かつ強凸な問題を扱い, 第二の実験では, ニューラルネットワークを用いた非凸な問題に対する実用的な有効性を評価する.

4.1 マッシュルームデータセットの二値分類問題

第一の実験として、理論解析の仮定を満たす平滑かつ強凸な問題の設定における比較の実験を行う。データセットには UCI Machine Learning Repository のマッシュルームデータセットを用いる。このデータセットは、キノコの形状・色・匂いなどの離散的特徴量から、食用か有毒かの二値分類を行うものである。データ数は $N = 8124$ 、特徴量次元数は $d = 22$ (数値変換後) である [11]。モデルには線形モデルを用い、ロジスティック回帰による二値分類を行う。目的関数は、L2 正則化付き二値交差エントロピー損失として次式で定義する。

$$f(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \ell_{\text{BCE}}(y_n, \hat{y}_n(\mathbf{w})) + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (38)$$

ここで $\ell_{\text{BCE}}(y, \hat{y}) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$ は二値交差エントロピー損失であり、 $\hat{y}_n(\mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x}_n + b)$ はシグモイド関数 σ を用いた予測値、 b はバイアス項 (閾値) である。この目的関数は L -平滑であり、L2 正則化項 ($\lambda > 0$) の存在により μ -強凸 ($\mu = \lambda$) となるため、理論解析の仮定 1-4 を満たす。

比較手法は SGD, SVRG, NFG SVRG, および提案手法である ASAI SVRG の 4 手法とする。

各実験では、3 種類の横軸と 3 種類の縦軸を組み合わせたグラフにより手法を比較する。横軸には、(1) 勾配計算回数 (オラクル呼び出し回数に相当し、SVRG 論文 [4] における $\#\text{grad}/N$ に対応する)、(2) エポック数、(3) 実行時間 (wall-clock time) を用いる。縦軸には、(1) 目的関数の誤差 $f(\mathbf{z}_s) - f(\mathbf{w}^*)$ 、(2) 分類精度 (accuracy)、(3) フル勾配の近似誤差 $\|\mathbf{e}_s\|^2$ を用いる。

4.2 CNN と CIFAR-10 の多値分類問題

第二の実験として、理論の仮定を満たさない非凸な問題の設定における比較の実験を行い、提案手法の実用的な有効性を評価する。

データセットには CIFAR-10 を用いる。CIFAR-10 は 32×32 ピクセルのカラー画像からなる 10 クラスの画像分類データセットであり、深層学習のベンチマークとして広く利用されている [10]。データ数は訓練データ $N = 50000$ 、テストデータ 10000 であり、各画像は $32 \times 32 \times 3$ のカラー画像 ($d = 3072$) である [12]。モデルには 3 層の畳み込みニューラルネットワーク (Convolutional Neural Network, CNN) を用いる。ネットワークは 3 つの畳み込み層と全結合層により構成される。目的関数は、多値交差エントロピー損失として次式で定義する。

$$f(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \ell_{\text{CCE}}(\mathbf{y}_n, \hat{\mathbf{y}}_n(\mathbf{w})) \quad (39)$$

ここで $\ell_{\text{CCE}}(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{c=1}^C y_c \log \hat{y}_c$ は多値交差エントロピー損失であり、 $C = 10$ はクラス数である。この実験では L2 正則化を用いない。ニューラルネットワー

クの非線形性により目的関数は非凸となるため、理論解析の仮定を満たさない。本実験は、理論的保証の範囲を超えた問題の設定に対する提案手法の実用的な有効性を検証することを目的とする。

比較手法は SGD, SVRG, NFG SVRG, および提案手法である ASAI SVRG の 4 手法とする。

評価の横軸・縦軸の組み合わせも第一の実験と同様に、横軸を勾配計算回数・エポック数・経過時間の 3 種類、縦軸を目的関数の値・分類精度・フル勾配の近似誤差 $\|\mathbf{e}_s\|^2$ の 3 種類とする。

5 おわりに

本稿では、有限和最小化に対する分散削減法として Averaged Snapshot Approximate Incremental SVRG (ASAI SVRG) を提案した。提案手法は、フル勾配の計算を確率的勾配の平均で代替しつつ、内ループで得られたパラメータの平均をスナップショットとすることでフル勾配の近似誤差を低減する。この設計は、パラメータ平均化の知見を SVRG の枠組みに取り入れたものであり、NFG SVRG の計算効率を保ちながら、より低い誤差床を理論的に保証する。ASAI SVRG は平均パラメータを戻り値とするため、Polyak-Ruppert Averaging と同様のノイズ低減効果が見込める。また、外ループごとに平均パラメータをリセットするため、学習の終盤では最適解の近傍にあるパラメータのみの平均となり、より優れた解へ収束しうる。本稿の貢献は次の 3 点である。第一に、平均パラメータをスナップショットとした ASAI SVRG を提案した。第二に、提案手法と関連手法を統一的なワークフローの下で収束の評価を行った。第三に、フル勾配を平均勾配で近似する際に、最良のスナップショットが平均パラメータであることを論理的に示した。理論解析により、SVRG は線形収束すること、NFG SVRG および ASAI SVRG は近似誤差に起因する誤差床へ収束すること、ならびに ASAI SVRG の近似誤差上界が NFG SVRG 以下であることを明らかにした。実験では、Mushroom データセットを用いた二値分類 (平滑かつ強凸な設定) および CIFAR-10 を用いた CNN 実験 (非凸な設定) により、提案手法の有効性を検証した。

今後の課題として、非凸目的関数への拡張、および内ループ長 K や学習率 η の実用的な設定指針の整備が挙げられる。

参考文献

- [1] H. Robbins and S. Monro, “A stochastic approximation method,” *Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.
- [2] L. Bottou, “Large-scale machine learning with stochastic gradient descent,” *Proc. COMPSTAT*, pp. 177–186, 2010.
- [3] Y. Nesterov, *Introductory Lectures on Convex Optimization*, Springer, 2004.
- [4] R. Johnson and T. Zhang, “Accelerating stochastic gradient descent using predictive variance re-

duction,” Advances in Neural Information Processing Systems (NeurIPS), vol. 26, pp. 315–323, 2013.

- [5] D. Medyakov, G. Molodtsov, S. Chezhegov, A. Rebrikov, and A. Beznosikov, “Variance reduction methods do not need to compute full gradients: Improved efficiency through shuffling,” arXiv:2502.14648, 2025.
- [6] B. T. Polyak, “New method of stochastic approximation type,” Automation and Remote Control, vol. 51, no. 7, pp. 937–946, 1990.
- [7] D. Ruppert, “Efficient estimations from a slowly convergent Robbins-Monro process,” Technical Report, Cornell University, 1988.
- [8] W. Tao, M. Li, S. Zhang, and J. Yi, “Primal averaging: A new gradient evaluation step to attain the optimal individual convergence,” IEEE Transactions on Cybernetics, vol. 48, no. 12, pp. 3369–3379, 2018.
- [9] A. Defazio, H. Mehta, X. Yang, K. Mishchenko, A. Khaled, and A. Cutkosky, “The road less scheduled,” Advances in Neural Information Processing Systems (NeurIPS), 2024.
- [10] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning, MIT Press, 2016.
- [11] D. Dua and C. Graff, “UCI Machine Learning Repository,” University of California, Irvine, 2017. <https://archive.ics.uci.edu/ml>
- [12] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.

A 補題の証明

補題 1 (勾配差分の平均の期待値の上界) Assumption 1 および Assumption 2 の下で, 任意の $\mathbf{w}$ に対して

$$\mathbb{E}_n[\|\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}^*)\|^2] \leq 2L(f(\mathbf{w}) - f(\mathbf{w}^*)) \quad (26)$$

が成り立つ.

Proof. $\mathbf{w} = \mathbf{w}^*$ で最小となる補助関数

$$\phi_n(\mathbf{w}) := f_n(\mathbf{w}) - f_n(\mathbf{w}^*) - \langle \nabla f_n(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle \quad (40)$$

を導入する. このとき

$$\nabla \phi_n(\mathbf{w}) = \nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}^*) \quad (41)$$

であり, $\phi_n(\mathbf{w}^*) = 0$ である. さらに Assumption 2 より $\phi_n(\mathbf{w}) \geq 0$ が成り立つ. Assumption 1 より, 任意の学習率の候補 $\eta > 0$ に対して

$$\begin{aligned} 0 &= \phi_n(\mathbf{w}^*) \\ &\leq \phi_n(\mathbf{w} - \eta \nabla \phi_n(\mathbf{w})) \\ &\leq \phi_n(\mathbf{w}) - \eta \|\nabla \phi_n(\mathbf{w})\|^2 + \frac{L}{2} \eta^2 \|\nabla \phi_n(\mathbf{w})\|^2 \end{aligned} \quad (42)$$

が成り立つ. 右辺を η の関数

$$\psi(\eta) := \phi_n(\mathbf{w}) - \eta \|\nabla \phi_n(\mathbf{w})\|^2 + \frac{L}{2} \eta^2 \|\nabla \phi_n(\mathbf{w})\|^2 \quad (43)$$

とおき, $\frac{d\psi}{d\eta} = 0$ から最適値 $\eta^* = 1/L$ を得る. これを代入すると

$$0 \leq \psi(\eta^*) = \phi_n(\mathbf{w}) - \frac{1}{2L} \|\nabla \phi_n(\mathbf{w})\|^2 \quad (44)$$

となる. したがって

$$\begin{aligned} &\|\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}^*)\|^2 \\ &\leq 2L \left(f_n(\mathbf{w}) - f_n(\mathbf{w}^*) - \langle \nabla f_n(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle \right) \end{aligned} \quad (45)$$

である. 全データ $n = 1, \dots, N$ について平均をとると

$$\begin{aligned} &\frac{1}{N} \sum_{n=1}^N \|\nabla f_n(\mathbf{w}) - \nabla f_n(\mathbf{w}^*)\|^2 \\ &\leq 2L \frac{1}{N} \sum_{n=1}^N \left(f_n(\mathbf{w}) - f_n(\mathbf{w}^*) - \langle \nabla f_n(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle \right) \\ &= 2L(f(\mathbf{w}) - f(\mathbf{w}^*)) \end{aligned} \quad (46)$$

となる. ここで $\frac{1}{N} \sum_{n=1}^N \nabla f_n(\mathbf{w}^*) = \nabla f(\mathbf{w}^*) = \mathbf{0}$ を用いた. よって (26) が成り立つ. $\square$

補題 2 (補正勾配の分散) Assumption 1 の下で

$$\begin{aligned} \mathbb{E}_{n_s^k} [\|\mathbf{v}_s^k\|^2] &\leq 6L(f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + 18L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) + 6\|\mathbf{e}_s\|^2 \end{aligned} \quad (27)$$

が成り立つ。

Proof. (23) において

$$\begin{aligned} \mathbf{a} &= \nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{w}^*), \\ \mathbf{b} &= \nabla f_{n_s^k}(\mathbf{z}_s) - \nabla f_{n_s^k}(\mathbf{w}^*), \\ \mathbf{c} &= \mathbf{g}_s \end{aligned} \quad (47)$$

とおくと,

$$\mathbf{v}_s^k = \mathbf{a} - \mathbf{b} + \mathbf{c} \quad (48)$$

である。不等式 $\|\mathbf{a} - \mathbf{b} + \mathbf{c}\|^2 \leq 3\|\mathbf{a}\|^2 + 3\|\mathbf{b}\|^2 + 3\|\mathbf{c}\|^2$ より

$$\begin{aligned} \mathbb{E}_{n_s^k} [\|\mathbf{v}_s^k\|^2] &\leq 3\mathbb{E}_{n_s^k} [\|\nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{w}^*)\|^2] \\ &\quad + 3\mathbb{E}_{n_s^k} [\|\nabla f_{n_s^k}(\mathbf{z}_s) - \nabla f_{n_s^k}(\mathbf{w}^*)\|^2] \\ &\quad + 3\|\mathbf{g}_s\|^2 \end{aligned} \quad (49)$$

となる。(26) より, 右辺第 1 項および第 2 項は

$$3\mathbb{E}_{n_s^k} [\|\nabla f_{n_s^k}(\mathbf{w}_s^k) - \nabla f_{n_s^k}(\mathbf{w}^*)\|^2] \leq 6L(f(\mathbf{w}_s^k) - f(\mathbf{w}^*)), \quad (50)$$

$$3\mathbb{E}_{n_s^k} [\|\nabla f_{n_s^k}(\mathbf{z}_s) - \nabla f_{n_s^k}(\mathbf{w}^*)\|^2] \leq 6L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) \quad (51)$$

と評価できる。さらに $\mathbf{g}_s = \mathbf{e}_s + \nabla f(\mathbf{z}_s)$ より

$$\begin{aligned} \|\mathbf{g}_s\|^2 &= \|\mathbf{e}_s + \nabla f(\mathbf{z}_s)\|^2 \\ &\leq 2\|\mathbf{e}_s\|^2 + 2\|\nabla f(\mathbf{z}_s)\|^2 \\ &= 2\|\mathbf{e}_s\|^2 + 2\|\nabla f(\mathbf{z}_s) - \nabla f(\mathbf{w}^*)\|^2 \\ &\leq 2\|\mathbf{e}_s\|^2 + 4L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) \end{aligned} \quad (52)$$

である。ここで最後の不等式には, $\|\nabla f(\mathbf{z}_s)\|^2 \leq 2L(f(\mathbf{z}_s) - f(\mathbf{w}^*))$ を用いた。したがって

$$3\|\mathbf{g}_s\|^2 \leq 6\|\mathbf{e}_s\|^2 + 12L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) \quad (53)$$

となる。(50), (51), (53) を (49) へ代入すると, (27) が成り立つ。□

補題 3 (最適解と現在のパラメータの距離の期待値の上界) $0 < \eta < 1/(3L)$ の下で

$$\begin{aligned} c_1 \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] &\leq \left(Kc_2 + \frac{2}{\mu}\right) \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] \\ &\quad + Kc_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (29)$$

が成り立つ。

Proof. 更新則 $\mathbf{w}_s^{k+1} = \mathbf{w}_s^k - \eta \mathbf{v}_s^k$ より

$$\begin{aligned} \mathbb{E}_{n_s^k} [\|\mathbf{w}_s^{k+1} - \mathbf{w}^*\|^2] &= \mathbb{E}_{n_s^k} [\|\mathbf{w}_s^k - \mathbf{w}^* - \eta \mathbf{v}_s^k\|^2] \\ &= \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 - 2\eta \langle \mathbb{E}_{n_s^k} [\mathbf{v}_s^k], \mathbf{w}_s^k - \mathbf{w}^* \rangle \\ &\quad + \eta^2 \mathbb{E}_{n_s^k} [\|\mathbf{v}_s^k\|^2] \\ &= \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 - 2\eta \langle \nabla f(\mathbf{w}_s^k), \mathbf{w}_s^k - \mathbf{w}^* \rangle \\ &\quad - 2\eta \langle \mathbf{e}_s, \mathbf{w}_s^k - \mathbf{w}^* \rangle + \eta^2 \mathbb{E}_{n_s^k} [\|\mathbf{v}_s^k\|^2] \end{aligned} \quad (54)$$

となる。ここで (24) を用いた。Assumption 3 より

$$\langle \nabla f(\mathbf{w}_s^k), \mathbf{w}_s^k - \mathbf{w}^* \rangle \geq f(\mathbf{w}_s^k) - f(\mathbf{w}^*) + \frac{\mu}{2} \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 \quad (55)$$

である。また Cauchy-Schwarz の不等式と Young の不等式より

$$\begin{aligned} -2\eta \langle \mathbf{e}_s, \mathbf{w}_s^k - \mathbf{w}^* \rangle &\leq 2\eta \|\mathbf{e}_s\| \|\mathbf{w}_s^k - \mathbf{w}^*\| \\ &\leq \eta \mu \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 + \frac{\eta}{\mu} \|\mathbf{e}_s\|^2 \end{aligned} \quad (56)$$

が成り立つ。(55) と (56) を (54) へ代入すると, $\eta \mu \|\mathbf{w}_s^k - \mathbf{w}^*\|^2$ の項が打ち消し合い

$$\begin{aligned} \mathbb{E}_{n_s^k} [\|\mathbf{w}_s^{k+1} - \mathbf{w}^*\|^2] &\leq \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 - 2\eta (f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + \frac{\eta}{\mu} \|\mathbf{e}_s\|^2 + \eta^2 \mathbb{E}_{n_s^k} [\|\mathbf{v}_s^k\|^2] \end{aligned} \quad (57)$$

となる。さらに (27) を代入すると

$$\begin{aligned} \mathbb{E}_{n_s^k} [\|\mathbf{w}_s^{k+1} - \mathbf{w}^*\|^2] &\leq \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 - 2\eta (f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + 6\eta^2 L(f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + 18\eta^2 L(f(\mathbf{z}_s) - f(\mathbf{w}^*)) \\ &\quad + \left(6\eta^2 + \frac{\eta}{\mu}\right) \|\mathbf{e}_s\|^2 \\ &= \|\mathbf{w}_s^k - \mathbf{w}^*\|^2 - c_1 (f(\mathbf{w}_s^k) - f(\mathbf{w}^*)) \\ &\quad + c_2 (f(\mathbf{z}_s) - f(\mathbf{w}^*)) + c_3 \|\mathbf{e}_s\|^2 \end{aligned} \quad (58)$$

を得る. $0 < \eta < 1/(3L)$ のとき $c_1 > 0$ である. (58) の両辺の全期待値をとり, タワー則を用いると

$$\begin{aligned} & \mathbb{E}[\|\mathbf{w}_s^{k+1} - \mathbf{w}^*\|^2] \\ & \leq \mathbb{E}[\|\mathbf{w}_s^k - \mathbf{w}^*\|^2] - c_1 \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \\ & \quad + c_2 \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] + c_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (59)$$

となる. $k = 0, 1, \dots, K-1$ について総和をとる望遠和により

$$\begin{aligned} & c_1 \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \\ & \leq \mathbb{E}[\|\mathbf{w}_s^0 - \mathbf{w}^*\|^2] - \mathbb{E}[\|\mathbf{w}_s^K - \mathbf{w}^*\|^2] \\ & \quad + Kc_2 \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] + Kc_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (60)$$

を得る. $-\mathbb{E}[\|\mathbf{w}_s^K - \mathbf{w}^*\|^2] \leq 0$, および $\mathbf{w}_s^0 = \mathbf{z}_s$ と (20) より

$$\mathbb{E}[\|\mathbf{w}_s^0 - \mathbf{w}^*\|^2] \leq \frac{2}{\mu} \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] \quad (61)$$

であるから, (29) が成り立つ. $\square$

B 定理の証明

定理 1 (各手法の収束特性) Assumption 1–4 の下で $0 < \eta < 1/(3L)$ とし, 定数 c_1, c_2, c_3 を (28) で, 収縮係数 ρ を (30) で定める. $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ からランダム選択する場合, または ASAI (パラメータ平均) のいずれにおいても

$$\mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \leq \rho \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] + \frac{c_3}{c_1} \mathbb{E}[\|\mathbf{e}_s\|^2] \quad (31)$$

が成り立つ.

Proof. $\mathbf{z}_{s+1}$ を $\{\mathbf{w}_s^k\}_{k=0}^{K-1}$ から一様ランダムに選ぶ場合,

$$\mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (32)$$

である. したがって

$$K \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] = \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (33)$$

となる. 一方, $\mathbf{z}_{s+1} = \frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k$ とする ASAI の場合は, Assumption 2 より f は凸であるから Jensen の不等式が使え,

$$f(\mathbf{z}_{s+1}) = f\left(\frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_s^k\right) \leq \frac{1}{K} \sum_{k=0}^{K-1} f(\mathbf{w}_s^k) \quad (34)$$

となる. よって同様に

$$K \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \leq \sum_{k=0}^{K-1} \mathbb{E}[f(\mathbf{w}_s^k) - f(\mathbf{w}^*)] \quad (35)$$

が成り立つ. いずれの場合も補題 3 ((29)) より

$$\begin{aligned} & Kc_1 \mathbb{E}[f(\mathbf{z}_{s+1}) - f(\mathbf{w}^*)] \\ & \leq \left(Kc_2 + \frac{2}{\mu}\right) \mathbb{E}[f(\mathbf{z}_s) - f(\mathbf{w}^*)] \\ & \quad + Kc_3 \mathbb{E}[\|\mathbf{e}_s\|^2] \end{aligned} \quad (36)$$

となり, 両辺を Kc_1 で割ると (31) を得る. $\square$

定理 2 (誤差床の上界比較) Assumption 1–4 の下で, 同一の内ループの軌跡に対して

$$\mathbb{E}[\|\mathbf{e}_s^{\text{ASAI}}\|^2] \leq \mathbb{E}[\|\mathbf{e}_s^{\text{NFG}}\|^2] \quad (37)$$

が成り立つ. すなわち, 平均パラメータはスナップショットとして最良の選択である. したがって (31) の誤差床は ASAI SVRG において NFG SVRG 以下である.

Proof. $\mathbf{g}_s$ を直前内ループの確率的勾配平均

$$\mathbf{g}_s = \frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) \quad (62)$$

とする. このとき

$$\begin{aligned} \mathbf{e}_s &= \mathbf{g}_s - \nabla f(\mathbf{z}_s) \\ &= \frac{1}{K} \sum_{k=0}^{K-1} \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{z}_s) \\ &= \frac{1}{K} \sum_{k=0}^{K-1} \left(\nabla f(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{z}_s) \right) \\ & \quad + \frac{1}{K} \sum_{k=0}^{K-1} \left(\nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{w}_{s-1}^k) \right) \end{aligned} \quad (63)$$

と分解できる.

$$\begin{aligned} \mathbf{d}_{s-1}^k &:= \nabla f(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{z}_s), \\ \mathbf{r}_{s-1}^k &:= \nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{w}_{s-1}^k). \end{aligned} \quad (64)$$

とおくと, $\mathbb{E}[\mathbf{r}_{s-1}^k \mid \mathbf{w}_{s-1}^k] = \mathbf{0}$ である. ここで $\mathbf{d}_{s-1}^k$ はミニバッチの選択に依存しない決定論的な項を表し, $\mathbf{r}_{s-1}^k$ はミニバッチの選択が介入する確率的な項を表す. Jensen の不等式より

$$\begin{aligned}
& \mathbb{E}[\|\mathbf{e}_s\|^2] \\
&= \mathbb{E}\left[\left\|\frac{1}{K} \sum_{k=0}^{K-1} (\mathbf{d}_{s-1}^k + \mathbf{r}_{s-1}^k)\right\|^2\right] \\
&\leq \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[\|\mathbf{d}_{s-1}^k + \mathbf{r}_{s-1}^k\|^2] \\
&= \frac{1}{K} \sum_{k=0}^{K-1} \left(\|\mathbf{d}_{s-1}^k\|^2 + 2\langle \mathbf{d}_{s-1}^k, \mathbb{E}[\mathbf{r}_{s-1}^k \mid \mathbf{w}_{s-1}^k] \rangle \right. \\
&\quad \left. + \mathbb{E}[\|\mathbf{r}_{s-1}^k\|^2] \right) \\
&= \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{z}_s)\|^2 \\
&\quad + \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[\|\nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{w}_{s-1}^k)\|^2] \quad (65)
\end{aligned}$$

となる。Assumption 1 より第 1 項は

$$\frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{z}_s)\|^2 \leq \frac{L^2}{K} \sum_{k=0}^{K-1} \|\mathbf{w}_{s-1}^k - \mathbf{z}_s\|^2 \quad (66)$$

と抑えられる。ここで

$$\omega(\mathbf{z}_s) := \sum_{k=0}^{K-1} \|\mathbf{w}_{s-1}^k - \mathbf{z}_s\|^2 \quad (67)$$

を考えると

$$\begin{aligned}
\omega(\mathbf{z}_s) &= \sum_{k=0}^{K-1} (\|\mathbf{w}_{s-1}^k\|^2 - 2\langle \mathbf{w}_{s-1}^k, \mathbf{z}_s \rangle + \|\mathbf{z}_s\|^2) \\
&= \sum_{k=0}^{K-1} \|\mathbf{w}_{s-1}^k\|^2 - 2 \left\langle \mathbf{z}_s, \sum_{k=0}^{K-1} \mathbf{w}_{s-1}^k \right\rangle + K\|\mathbf{z}_s\|^2 \quad (68)
\end{aligned}$$

である。 $\frac{d\omega(\mathbf{z}_s)}{d\mathbf{z}_s} = \mathbf{0}$ より

$$-2 \sum_{k=0}^{K-1} \mathbf{w}_{s-1}^k + 2K\mathbf{z}_s = \mathbf{0} \quad \Rightarrow \quad \mathbf{z}_s^* = \frac{1}{K} \sum_{k=0}^{K-1} \mathbf{w}_{s-1}^k \quad (69)$$

を得る。すなわち $\omega(\mathbf{z}_s)$ は平均パラメータで最小化される。一方、(65) の第 2 項

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[\|\nabla f_{n_{s-1}^k}(\mathbf{w}_{s-1}^k) - \nabla f(\mathbf{w}_{s-1}^k)\|^2] \quad (70)$$

はスナップショットの選択方法に依らない項であり、Assumption 4 より有界である。したがって、平均パラメー

タをスナップショットとする ASAI SVRG は、ランダム選択を用いる NFG SVRG に比べ (66) の項を小さく抑えられる。よって (37) が成り立ち、(31) の右辺第二項が ASAI SVRG でより小さくなるため、誤差床も小さくなる。 $\square$